

Нормализация признаков

Данное задание основано на материалах лекции по линейным методам классификации.

Вы научитесь:

- работать с перцептроном — простейшим вариантом линейного классификатора
- повышать качество линейной модели путем нормализации признаков

Введение

Линейные алгоритмы — распространенный класс моделей, которые отличаются своей простотой и скоростью работы. Их можно обучать за разумное время на очень больших объемах данных, и при этом они могут работать с любыми типами признаков — вещественными, категориальными, разреженными.

Как и в случае с метрическими методами, качество линейных алгоритмов зависит от некоторых свойств данных. В частности, признаки должны нормализованы, то есть иметь одинаковый масштаб. Если это не так, и масштаб одного признака сильно превосходит масштаб других, то качество может резко упасть.

Один из способов нормализации заключается в стандартизации признаков. Для этого берется набор значений признака на всех объектах, вычисляется их среднее значение и стандартное отклонение. После этого из всех значений признака вычитается среднее, и затем полученная разность делится на стандартное отклонение.

Реализация в Scikit-Learn

В библиотеке scikit-learn линейные методы реализованы в пакете `sklearn.linear_model`. Мы будем работать с реализацией персептрона `sklearn.linear_model.Perceptron`. Как и у большинства моделей, обучение производится с помощью функции `fit`, построение прогнозов — с помощью функции `predict`.

Пример использования:

```
import numpy as np
from sklearn.linear_model import Perceptron
X = np.array([[1, 2], [3, 4], [5, 6]])
y = np.array([0, 1, 0])
clf = Perceptron()
clf.fit(X, y)
predictions = clf.predict(X)
```

Для стандартизации признаков удобно воспользоваться классом `sklearn.preprocessing.StandardScaler`.

Пример использования:

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_train = np.array([[100.0, 2.0], [50.0, 4.0], [70.0, 6.0]])
X_test = np.array([[90.0, 1], [40.0, 3], [60.0, 4]])
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Инструкция по выполнению

1. Загрузите обучающую и тестовую выборки из файлов `perceptron-train.csv` и `perceptron-test.csv`.
2. Обучите персептрон со стандартными параметрами и `random_state=241`.
3. Подсчитайте качество (долю правильно классифицированных объектов, ассигасу) полученного классификатора на тестовой выборке.
4. Нормализуйте обучающую и тестовую выборку с помощью класса `StandardScaler`.

5. Обучите персептрон на новых выборках. Найдите долю правильных ответов на тестовой выборке.
6. Найдите разность между качеством на тестовой выборке после нормализации и качеством до нее. Это число и будет ответом на задание.

При необходимости округляйте ответ до трех знаков после запятой.

Ответ на каждое задание — текстовый файл, содержащий ответ в первой строчке. Обратите внимание, что отправляемые файлы не должны содержать пустую строку в конце. Данный нюанс является ограничением платформы Coursera. Мы работаем над тем, чтобы убрать это ограничение.